

Lab4 实验报告

杨杰 201908010705

实验要求

主要工作

1. 阅读[cminus-f 的语义规则](#)成为语言律师，我们将按照语义实现程度进行评分
2. 阅读[LightIR 核心类介绍](#)
3. 阅读[实验框架](#)，理解如何使用框架以及注意事项
4. 修改 `src/cminusfc/cminusf_builder.cpp` 来实现自动 IR 产生的算法，使得它能正确编译任何合法的 cminus-f 程序
5. 在 `report.md` 中解释你们的设计，遇到的困难和解决方案

PS: 在lab3 里面由人将 c 翻译成 cpp 的工作，在 lab4 里，我们需要通过对抽象语法树的结点自顶向下遍历，让机器自动生成对应的 cpp 文件。

需要阅读的材料

- cminus-f 的语义规则
- LightIR 核心类介绍：重点看 c++ 的核心类介绍，以及各个类的使用方法，他们实现在 `/lab4/src/lightir` 中。
- 理解访问者模式下，算法的执行流程，参考- 打印抽象语法树的算法 `/src/common/ast.cpp`
- 理解助教给出的，用于存储作用域类 Scope：它是用来辅助我们在遍历语法树时，管理不同作用域中的变量。它提供以下接口：

```
// 进入一个新的作用域
void enter();
// 退出一个作用域
void exit();
// 往当前作用域插入新的名字->值映射
bool push(std::string name, Value *val);
// 根据名字，寻找到值
Value* find(std::string name);
// 判断当前是否在全局作用域内
bool in_global();
```

你们需要根据语义合理调用 `enter` 与 `exit`，并且在变量声明和使用时正确调用 `push` 与 `find`。

在类 `CminusfBuilder` 中，有一个 `Scope` 类型的成员变量 `scope`，它在初始化时已经将 `input`、`output`、`neg_idx_except` 等函数加入了作用域中。因此，你们在进行名字查找时不需要顾虑是否需要特殊函数进行特殊操作。

工作内容的理解

1. 我们需要实现的函数是 CminusfBuilder 类中的一系列成员函数。

由 .cpp 生成 .ll 的过程可以理解为：自顶向下遍历抽象语法树的每一个结点，利用访问者模式，调用我们写的成员函数，对每一个抽象语法树的结点进行分析，使之符合 cminusf 的语法和语义规则。

2. 从函数的传入参数开始，理解 visit 函数的工作流程：以第一个函数为例

```
void CminusfBuilder::visit(ASTProgram &node){}
```

传入参数为--抽象语法生成树上的一个结点（这里是根节点），结点类型为 `ASTProgram`

它的孩子是 declaration-list：

```
//ast.hpp
struct ASTProgram : ASTNode {
    virtual void accept(ASTVisitor &) override final;
    std::vector<std::shared_ptr<ASTDeclaration>>
        declarations;
};
```

也就是说，当我们遇到 ASTProgram 这个结点，需要做的事情是，向下遍历 (accept) 它的孩子，正如 cminusf 语法规则所要求的那样：`program → declaration-list`

此时，如果对应的 cminusf 语义有其他要求【具体信息来自实验文档】，也应该在这里实现【使用 lightir 核心类】。

最终的函数代码实现：

```
void CminusfBuilder::visit(ASTProgram &node) {
    // program -> declaration-list 深度优先遍历
    for(auto n : node.declarations){ // n 获取 declaration-list
        n->accept(*this); // visit all declaration-list
    }
}
```

3. accept() 函数的理解：

参考打印抽象语法生成树的代码，可以将 accept() 理解成一个递归调用，即向下递归遍历孩子结点。

实验难点

VarDeclaration

- 需要利用 `scope.in_global()` 来区分变量是在全局还是局部；
- 如果声明的是数组，需要检查数组下标 `node.num->i_val` 的值是否大于零；
- 根据 cminus-f 语义要求，全局变量需要初始化为 0；

FunDeclaration

一共需要进入两个子域：

1. 维护函数的参数及其返回值类型；
2. 维护函数输入的参数值和函数体内部语句；

紧跟着的 `Param` 用来分析函数的参数类型，并把参数 `push` 到作用域中；

- 注意如果参数是数组，则为数组引用传递（指针），且不需要考虑数组下标是否合法，因为根据 `cminus-f` 语法，这里的数组不会有下标。

`CompoundStmt` 维护函数体内部语句，根据语法向下遍历即可；

AssignExpression

`$expression -> var = expression$`

把 `expression` 的值赋给 `var`；

1. `var` 可以是一个整型变量、浮点变量，或者一个取了下标的数组变量。
2. 通过全局变量 `ret` 获取的 `expression` 的返回值有：`int`, `float`, `int*`, `float*` [表示返回的是存放 `expression` 值的地址], `int1`，五种类型。需要分别讨论这些情况。
3. 在 `expression_value` 和 `var_value` 的类型不同时，需要以 `var_value_type` 为标准，对 `expression_value` 做强制类型转换。

SimpleExpression

`simple-expression -> additive-expression relop additive-expression | additive-expression`

- 浮点数和整型数一起运算时，整型值需要进行类型提升，转成浮点类型，其运算结果也是浮点类型；

Selection statement

- 首先，我们需要向下遍历 `if` 的判据（即 `expression`）：
 1. `expression` 类型：指针（`int`, `float` 型），`int`, `float`, `bool`。
 2. 如果是指针的话，我们需要将指针指向的值 `load` 出来。
 3. 如果是 `bool` 类型，则将其强制类型转换为 `int32` 类型。
 4. 这样最后都会转化为 `int32` 或者 `float` 类型。用对应的 `cmp` 函数比较其值是否为 0 即可。
 5. 作为分支判据的 `expression` 的处理都是类似的，后面的 `iterationstmt` 实现方案和 `selectionstmt` 是非常相似的，所以后面 `iteration` 部分不再赘述
- 其次还要检测 `selection stmt` 展开之后是什么类型，有没有 `else stmt`，如果有的话就创建真假分支后创建跳出分支，没有的话只需要创建真分支和跳出分支即可
- 注意到，在每个 `statement` 内部，我们需要考虑 `statement` 内 `return`
- 在 `selection stmt` 和后面的 `iteration stmt` 中，为了解决 `if` 嵌套 `if`，`while` 嵌套 `while` 的情况，建议在创建 `Basicblock` 的时候，使用默认的寄存器编号作为名字，不然可能会出现嵌套时分支重名的情况

Return statement

- 由于 `expression` 可能类型的多样性，如果是指针类型，我们需要把指针 `load` 成一个对应的值
- 若 `return void`；则直接创建空返回就好
- 要注意到：我们需要用 `builder->get_insert_block()->get_parent()->get_return_type()` 来检测函数返回值类型与我们实际要返回的类型是否相同，如果不同，则要进行强制类型转换，比如

```

else if ((ret->get_type() == typeint && builder->get_insert_block()-
>get_parent()->get_return_type() == typefloat))
{
    auto ret_load = builder->create_sitofp(ret, typefloat);
    builder->create_ret(ret_load);
}

```

Var

- 首先需要在scope中找到id
- 因为var可能被展开成单纯的ID或者ID[expression]，即数组类型，于是我们需要根据是否有expression进行讨论
- 如果是纯id，则返回id地址即可
- 如果不是，则是数组类型，即ID [expression]
- 先讨论expression，因为expression类型的多样性，这里对于最终的数组下标而言，我们需要的是一个int32，所以需要将它们全部转化为int32。
- 然后由于数组下标非负的限制，我们需要创建一个判断分支去看是否大于0（value*不能直接用if语句比大小），true分支里面，讨论一下id的类型，id的类型可能是：int**，float**，int*，float*，后面两个类型是普通的整数和浮点数数组类型，对于int**和float**类型，它本质上是一个指针，指向了一块内存空间，这个内存空间存放了数组首地址。我们希望将数组取出来，这部分主要是用于数组传参，后面实验设计部分会有更加详细的解释。到最后，任意id都会成为int*，float*类型，然后用create_gep取值并返回即可
- 如果数组下标小于0，则调用neg_idx_except报错

ASTAdditiveExpression

additive_expression 可以生成两种表达式，分别是 term 和 additive_expression addop term。

1. 如果是 term，那么直接调用它的accept函数，就可以完成访问者遍历并跳转到子节点（term）
2. 如果是 additive_expression addop term，那么要对加减法符号两端对操作数进行类型转换。
3. 最后根据操作数是int还是float来调用相应的加减法函数

ASTTerm

term 和 additive_expression 的产生式形式相同，处理方式几乎完全一样

ASTCall

call分为两部分，即函数名的处理和函数传入参数列表的处理。

对于函数名，需要做的是进入到它对应的作用域里面，并取出函数声明时的形参列表（用于检查和传入参数是否一致）。

对于传入参数，需要将指针/数组元素对应的值“取出来”，存入vector中，并与声明时的参数列表比较类型

这个函数的难点：

1. 函数调用的参数可以为空；
2. 需要检查调用时实参和函数声明时参数的个数和类型是否一致，如果不一致，在必要时需要进行强制类型转换；

获取被调用函数的参数类型列表的方法：

```

/* enter the scope of terminal symbol ID */
auto IDalloc = scope.find(node.id);
auto fun = IDalloc->get_type();
auto callFun = static_cast<FunctionType *>(fun);
std::vector<Type *> params; // get the params value of the function

```

这里不用考虑数组的类型不一致问题。

实验设计

全局变量 ret

存放 expression 的返回值，以便需要时可以直接获取；

- 该返回值可以从 Num 中得到 -> 一个数字(int or float)；
- 从关系计算式得到 -> int1
- 通过简单的运算或者从数组中取出，这时存放的是对应值的地址 -> int* or float*

如何处理数组传参

请看这个函数

```
int func_array(int a[])
```

在这个函数中，**数组首地址**作为形参传入 `int func_array(int a[])`，函数会开辟一块内存来存储形参。在 `int func_array(int a[])` 中，形参类型是 `int*`，指向存储 `int*` 内存空间的指针类型是 `int**`。针对这类情况，我们处理 `int**` 或者 `float**` 的流程如下，在下面函数中，`id_type` 是 `id` 的类型：

- 首先，将 `id` 当成一个二维数组，使用 `create_gep` 函数 `id_load = builder->create_gep(id_type, {CONST_INT(0), CONST_INT(0)})`；取出内存空间中存放的数组首地址。
- 再用 `id_load = builder->create_gep(id_load, {temp_ret})`；(`temp_ret` 是数组下标)取得 `id[temp_ret]` 的地址

通过这两个步骤，我们可以访问传进子函数的数组中的任意元素

降低生成 IR 中的冗余 -- 丢掉同一块内 return 后的语句

主要思想：

1. 设置全局变量标识遍历到的结点之前是否出现过 `return` 语句，初始化为0；`int isAfterRetrun = 0;`
2. 在每个结点的函数开始处，判断 `isAfterRetrun` 是否为0；若是，则可以继续分析，若不是，则不对其进行任何处理（丢掉冗余结点的分析）。
3. 每个 `return` 结点遍历结束时，`isAfterRetrun = 1;`
4. 每个函数执行结束时，重置 `isAfterRetrun = 0;`
5. 每个 `while` 块执行结束时，`isAfterRetrun = 0;`
6. `if-statement`，没有 `else` 分支，且在 `if` 分支内部出现了 `return`：

```
node.if_statement->accept(*this);

if (isAfterReturn){
    localFlag = 1; // 区分 if-then 和 if-then-else
    isAfterReturn = 0;
}
```

7. `if-then-else` 分别讨论只在一个分支出现 `return` 和两个分支都出现 `return` 的情况：

```
if (isAfterReturn){
    localFlag_2 = 1;
    if (localFlag){
        isAfterReturn = 1; // if & else 都有 return , 则 if-else 后的代码块没有
        必要执行;
    }
    else
    {
        isAfterReturn = 0;
    }
}
```

结果验证

```
(base) yj@myubuntu:~/Documents/编译原理/cminus_compiler-2021-fall/tests/lab4$ python lab4_test.py
=====TEST START=====
Case 01:      Success
Case 02:      Success
Case 03:      Success
Case 04:      Success
Case 05:      Success
Case 06:      Success
Case 07:      Success
Case 08:      Success
Case 09:      Success
Case 10:      Success
Case 11:      Success
Case 12:      Success
=====TEST END=====
```

实验总结

深入理解了中间代码的生成过程。

最大的感受是发明编译器的前辈们实在是太厉害了，clang 生成的 .ll 文件精简又准确，在函数需要返回语句，但缺少时，甚至能自动补全一句 `return`；

编译器就像一个优秀的翻译官，将我们的代码翻译成机器能听懂的语言的同时，对我们的语言进行了精简，使得机器运行的效率提高。

自己在写 c 程序的时候并没有关心过自己写的 c 语句是如何被机器识别成二进制代码。从学了编译原理，写了一次次实验之后，终于对代码的编译过程甚至是计算机行业有了更深入的了解。越来越觉得，计算机相关行业无一不是在让人们的生活变得更加便利和快捷，未来可期！

最开始写实验的时候尝试从 `call` 函数倒着写，最后发现是一个相当大的失误。对语法树的处理是自顶向下的，思维随着编译器，对一条语句自 `program` (root) 而下遍历，对途径的产生式展开和选择，每一个结点的处理才逐渐浮现在眼前。在后期调试和 `debug` 的过程中，也有一点别的体会，比如对于 `return` 之后冗余语句的省略，除了本次实验的实现方法外，我觉得还可以通过修改语法规则来实现优化：

$\text{compound-stmt} \rightarrow \{\text{local-declarations}\} \text{statement-list} \mid \text{return-stmt} \mid \text{redundancy-stmt}$

$\text{redundancy-stmt} \rightarrow \text{statement-list}$

$\text{statement} \rightarrow \text{expression-stmt} \mid \text{compound-stmt} \mid \text{selection-stmt} \mid \text{iteration-stmt}$